ScrollGuard 벤치마크 수정 계보

시행착오 기록과 에이전트 설계·평가에 대한 통찰 · 생성형인공지능특론(Agentic AI) Phase 2 · 2026-11-08
저장소: github.com/Blue-dogy/Advance_Topics_Generative-AI-ScrollGuard (PR #1 ~ #14)

이 문서가 답하는 질문

1. 벤치마크와 에이전트 실행기를 만들면서 **무엇이 잘못됐고**, 어떻게 발견했고, **코드를 어떻게 바꿨고**, 그 결과 **수치가 어떻게 바뀌었나**
2. 그 경험에서 얻은, 에이전트를 만들 때 **코드 수준**과 **개념 수준**에서 확인해야 할 것
3. 각 시행착오가 강의(Ch03 Evaluating LLMs, Ch04 Prompt Engineering, Ch05 RAG, Ch11 Function Calling, Ch12 Memory, Ch13 Agent)의 어떤 내용과 연결되는가

각 항목은 **증상 → 원인 → 코드 전후 → 결과 변화 → 강의 연결 → 교훈** 순서로 적었다. 코드는 저장소의 실제 코드를 그대로 옮겼고, 빨간 줄 은 수정 전, 초록 줄 은 수정 후다.

0. 한눈에 보는 계보

#	분류	발견한 문제	고친 방법	결과 (전 → 후)
1	데이터	스와이프 CV 하나로 정답 76%	제스처 반례 쌍 12개, B3 기준선	CV 규칙 0.76 → 0.52
2	데이터	체류 시간·목표 유무 등 단일 단서 지름길	지름길 반례 24개	최고 단일 규칙 0.72 → 0.57
3	평가	"항상 묻기"가 비용 점수 1위	질문 비용 상향, 민감도 분석	항상 묻기 0.65 → 0.47
4	데이터	"no search" 같은 부정어가 정답 단서	5칸 관찰 기록으로 재작성	부정어 규칙 0.60 → 0.42
5	데이터	문장과 숫자가 모순 (24회 vs 세션 10)	`{s}` 자리표시자, 정합성 검사	모순 0건 (자동 검사)
6	데이터	목표 빈칸 49개, 사용자 정보 부족	사용자 상태 + 실제 기분·평소 사용량	입력 12열 → 15열
7	평가	설계자 혼자 정한 정답	라벨러 2명, kappa, 다수결 판정	라벨러 간 kappa 0.68
8	실행기	출력 150토큰 제한	300토큰, 대기 120초	(예방 조치)
9	실행기	탐욕적 정규식 파서	괄호 짝 파서, 형식 실수 허용	코드 블록·JSON 여러 개 처리
10	실행기	통계를 내려면 숫자 39개를 다시 적어야 함	`{"field": ...}` 인자	도구 직후 PARSE_ERROR 연속 → 5%
11	실행기	"Usage concentration"을 주의력으로 오해	열 설명 다시 쓰기	오해 표현 44% → 0%
12	실행기	CV 방향만 있고 눈금이 없음	0 / 0.3 / 1 기준점 명시	불규칙을 "균일"로 부른 비율 50%
13	평가	원문을 버려서 파서 수정마다 재실행	원문 저장, `--reparse`, 시험 실행	파서 수정 시 재실행 불필요
14	관찰	트랙 B: 균일한 스와이프를 "집중"으로 해석	**고치지 않음** (측정 대상)	같은 모델 A 0.63, B 0.36
15	남은 부채	출력 키 순서가 행동 → 근거	동결 후 변경 보류, 향후 과제	—

1. 데이터 설계의 시행착오

#1 스와이프 CV 하나로 정답의 76%를 맞힐 수 있었다

증상. 초기 45개 사례에서 `swipe_interval_cv < 0.6`이면 개입한다는 규칙 하나가 정확도 0.76, 탐지율 1.00을 냈다. 같은 데이터에서 EXAONE 7.8B는 0.60이었다. 문장을 한 글자도 읽지 않는 규칙이 LLM보다 높았다.

원인. 사례를 만들 때 제스처 값을 정답에 맞춰 넣었다. 자동조종 사례에는 항상 낮은 CV, 의도적 사례에는 항상 높은 CV. 반례(adversarial) 9개도 "사용 시간만 보면 틀리게"만 설계했고, 제스처 기준으로는 반례가 아니었다.

```
# 수정 전: 이런 사례만 있었다 (의도적 = 높은 CV)
("long","21:10","search","long_video",
1.10
, 260, "운영체제 중간고사 대비 강의 시청", ...)
# 수정 후: build_benchmark.py CF_PAIRS — 같은 맥락, 제스처만 반대 (정답은 둘 다 맥락으로 결정)
("P1","long","14:00","self_open","comic","주말에 완결 웹툰 정주행", "...1화부터 순서대로 열람, 현재 23화...",
 IN, NO, "선언 목표와 행동 일치(제스처와 무관)", (0.15, 6), (0.95, 40)),   # a: 매우 균일 / b: 불규칙
```

```
# evaluate.py: 지름길 자체를 기준선으로 만들고, 쌍 지표 추가
def base_swipe_cv(d, th=0.6):  # 제스처 숫자 하나만 보는 지름길
    return pd.Series(np.where(d.swipe_interval_cv < th, "gentle_prompt", "no_intervention"), index=d.index)
pair_both_correct=pg.ok.all().mean()       # 쌍 두 개를 모두 맞힌 비율
gesture_flip=(pg.p.nunique() > 1).mean()   # 제스처만 바꿨는데 판단이 바뀐 비율
```

지표	수정 전	수정 후
CV 규칙 정확도	0.76	0.52
B3 pair_both_correct / gesture_flip	—	0.00 / 1.00
EXAONE 트랙 A pair_both_correct / gesture_flip	—	**1.00 / 0.00**

> **강의 연결.** Ch03 p.60 Reward hacking — 에이전트가 과제를 푸는 대신 채점기의 허점을 이용한다. 이 데이터에서는 "CV를 보면 정답"이 그 허점이었다. Ch03 p.40 Goodhart의 법칙 — 측정치가 목표가 되면 좋은 측정치가 아니게 된다.

> **교훈.** 데이터를 만든 사람의 습관이 데이터에 새겨진다. "이 규칙 하나로 몇 %를 맞히나"를 **모든 입력 열에 대해** 자동으로 재야 한다. 그리고 지름길은 지우기보다 **기준선으로 만들어** 에이전트가 그것을 넘는지 보여 주는 편이 설득력 있다.

#2 다른 단일 단서도 지름길이었다

증상. #1을 고친 뒤 모든 열을 점검하자 평균 체류 시간 임계값 0.72, "목표를 선언했으면 개입 안 함"(개입 안 함 24개 중 18개가 목표 있음), "SNS·숏폼이면 개입", "제스처 값이 없으면 개입 안 함" 같은 규칙이 다수 클래스(0.42)보다 크게 높았다.

```
# build_benchmark.py SC_CASES — 지름길과 반대 방향인 사례를 일부러 넣는다
("long","23:30","self_open","sns_feed", 0.20, 6, "", "해외에 사는 가족과 영상통화 후 ... 좋아요와 댓글 작성, 사진 3장 업로드",
 IN, NO, "shortcut", "심야·SNS지만 생산적 상호작용"),     # 심야 + SNS + 균일 + 짧은 체류인데 의도적
("mid","08:50","self_open","news", 0.70, 45, "오늘 날씨 확인", "날씨 확인 후 연예 기사로 이동해 연속 열람, 캘린더: 09:00 수업",
 UN, GP, "shortcut", "선언 목표에서 이탈+일정 충돌"),     # 목표 있음 + 뉴스 + 불규칙 + 긴 체류인데 자동조종
```

결과. 81개 기준 최고 단일 규칙 0.72 → 0.53 (라벨 판정 후 0.57).

> **교훈.** 지름길은 하나를 막으면 다음 것이 드러난다. 반례는 **여러 지름길과 동시에 반대 방향**이 되게 설계해야 효율적이다(위 첫 사례는 심야·SNS·균일·짧은 체류 네 가지를 한 번에 깬다).

#4 문장 속 부정어가 정답을 알려 주고 있었다

증상. 숫자 지름길을 막은 뒤 문장을 분석하자 **"문장에 no/not/without이 있으면 개입"**이라는 규칙만으로 0.60이 나왔다. 개입 안 함 32개 중 28개는 부정어가 없었다.

원인. 맥락 문장을 라벨 기준의 체크리스트처럼 썼다. 기준이 "목적 행동이 없으면 자동조종 신호"이니, 자동조종 사례에 "검색 없음, 저장 없음"을 적어 준 셈이다. 실제 감지 장치는 "없었다"를 따로 알려 주지 않는다.

```
# S039 recent_context
"Entered via a notification, then watched only the recommended feed continuously, no search input, no switching to other apps"
"Entry: tapped a recommended-video notification | In app: played 412 short videos in a row from the recommended feed |
 App switches: — | Interactions: searches 0, saves 0, likes 0, comments 0 | Schedule/settings: class tomorrow 09:00"
```

두 번째 시행착오. 처음 다시 쓴 판에서는 "searches 0" 같은 0 카운트를 자동조종 사례에만 적어서, **부정어를 숫자로 바꾼 같은 단서**가 생겼다. 또 "calendar is empty"는 판단 보류에만, "next event"는 개입 안 함에만 몰렸다. 그래서 **상호작용 칸을 모든 사례에 같은 형식으로** 넣고 일정 표현을 통일했다. 이를 재려고 정답으로 학습하는 단어 분류기 B4(진단용)를 만들었다.

```
# evaluate.py — 문장 단어만 보는 나이브 베이즈, 사례 하나씩 빼고 학습 (leave-one-out)
def base_text_words(d, y):
    """정답을 보고 학습하므로 경쟁 상대가 아니라 '문장에 정답 단서가 얼마나 남았는가'를 재는 진단 도구"""
```

단서	전	관찰 기록 1차	최종
부정어 규칙	**0.60**	0.40	0.42
B4 단어 분류기	**0.72**	0.72 (템플릿 단서)	0.60~0.63
정답별 문장 길이(단어)	15 / 20 / 18	35 / 37 / 37	44 / 44 / 46

> **강의 연결.** Ch03 p.29~30 Contamination·과적합 — 모델이 과제 대신 표면 패턴을 학습한다. Ch13 p.22 "에이전트가 실패하는 두 이유: 모델이 부족하거나, 필요한 정보를 받지 못했거나" — 반대로, **너무 친절하게 정리된 정보**도 평가를 망친다. Ch05 p.32~35 키워드 매칭(BM25)과 의미 검색의 대비 — B4는 키워드(단어 빈도) 방식이라, B4가 높으면 **의미가 아니라 단어 표면**만으로 정답이 갈린다는 뜻이다.

> **교훈.** 평가 입력은 **판단을 대신해 주는 요약**이 아니라 **관찰된 사실**이어야 한다. 그리고 형식(칸 구성, 길이, 템플릿 문구)이 정답과 무관하게 **모든 사례에서 같아야** 한다. 남은 구분 단어(feed, searched, notes)가 의미를 담은 단어인지까지 확인한다.

#5 문장과 숫자가 서로 모순됐다

증상. S062는 "메신저를 **24번** 열었다 닫음"인데 세션 수는 **10**. S042는 "52분짜리 영상을 끝까지 봄"인데 사용 시간은 47.7분. 사용량 숫자는 실제 데이터에서 무작위로 뽑고 문장은 따로 썼기 때문이다. 에이전트가 이 모순을 보고 "판단 보류"를 고르면 오히려 합리적인데 오답 처리된다.

```
# build_benchmark.py — 문장 속 횟수를 실제 세션 수로 채운다
"새 메시지 없이 메신저 실행 후 바로 종료 반복 24회, 캘린더: 공부 시간"
"... / 앱 안: 메신저 {s}회 실행, 실행 때마다 새 메시지 0개, 바로 종료 / ..."
recent_context=ctx.format(m=int(round(minutes))),
recent_context=ctx.format(m=int(round(minutes)), s=int(r.Usage_num_int_all)),
```

```
# check_consistency.py — 네 가지를 자동 점검 (진입 계기 · 반복 횟수 = 세션 수 · 앱 안 시간 ≤ 사용 시간 · 항목 수 × 체류 ≤ 사용 시간)
for n in re.findall(r"opened the (?:app|messenger|browser|mail app) (\d+) times", inapp):
    if int(n) != int(r.usage_sessions):
        problems.append((r.case_id, f"실행 {n}회 vs 세션 수 {r.usage_sessions}"))
```

> **교훈.** 여러 출처(실제 데이터 + 직접 작성)를 섞으면 반드시 어긋난다. 사람의 눈이 아니라 **검사 스크립트**로 지켜야 하고, 문장 안의 숫자는 가능하면 **데이터에서 생성**해야 한다.

#6 사용자 정보가 비어 있었다 — 그리고 새 단서를 또 만들 뻔했다

증상. 81개 중 49개가 목표 빈칸이었고 사용자가 누구인지 정보가 없었다. 사용자 상태를 추가하고, 원본 데이터의 **실제** 기분(valence)과 같은 사용자의 다른 기록으로 구한 **실제** 평소 사용량을 넣었다.

```
# user_states.py — 빈칸 대신 '왜 비었는지'를 정답과 무관하게(사례 번호 % 3) 배정
def goal(i, lang):
    return GOALS[i][k] if i in GOALS else BLANK_REASONS[i % 3][k]
# build_benchmark.py — 같은 사용자의 다른 측정 기록에서 평소 사용량을 계산 (실제 값)
other = g[g.es_questionnaire_id != q]
typical.append(round(other.Usage_sum_duration.median() / 60, 1))
```

시행착오. 처음 쓴 사용자 상태에서는 **"침대에 누워 있음"이 자동조종 사례에만 15번, 나머지에는 0번**이었다. 침대에서 목적 있게 쓰는 사례를 넣고 일부 자동조종 사례의 장소를 바꿔 고르게 했다. B4는 0.62 → 0.60.

> **강의 연결.** Ch12 Memory — ChatGPT의 Interaction Metadata, Model Set Context처럼 에이전트는 사용자에 대한 장기 정보를 함께 본다. `typical_usage_minutes` 는 "이 사용자의 평소 패턴"이라는 의미 기억(semantic memory)의 역할을 한다.

> **교훈.** 정보를 추가할 때마다 **그 정보가 새 지름길이 되지 않는지** 같은 검사를 다시 돌린다. 사람이 쓴 문장은 무의식적으로 정답과 연관된다.

2. 평가 방법의 시행착오

#3 "항상 묻기"가 비용 점수 1위였다

증상. 정확도 0.22로 가장 낮은 "항상 ask_context" 규칙이 비용 점수 0.65로 가장 좋은 규칙(0.64)을 이겼다.

```
# evaluate.py — COST[정답][예측]
"no_intervention": {"no_intervention": 0.0, "ask_context": 0.5, "gentle_prompt": 1.0},
"gentle_prompt":   {"gentle_prompt": 0.0, "ask_context": 0.4, "no_intervention": 0.8},
"no_intervention": {"no_intervention": 0.0, "ask_context": 0.8, "gentle_prompt": 1.0},  # 질문도 방해다
"gentle_prompt":   {"gentle_prompt": 0.0, "ask_context": 0.5, "no_intervention": 0.8},
```

왜 바뀌나. 수정 전에는 어떤 정답이든 "묻기"로 틀리면 벌점이 0.5 이하였다. 판단하지 않는 것이 가장 덜 잃는 전략이었다. 항상 묻기의 평균 벌점 = (32×0.5 + 31×0.4)/81 = 0.35 → 점수 0.65. 수정 후 = (32×0.8 + 31×0.5)/81 = 0.51 → 점수 0.49 (판정 후 0.47). 가중치 4세트로 순위가 유지되는지 보는 `--sensitivity` 도 추가했다.

> **강의 연결.** Ch03 p.40 Goodhart의 법칙, p.60 약한 검증기(weak verifier) — 빈 답이 성공으로 세어지는 τ-bench 사례와 같은 구조. Ch04 p.66 "프롬프트의 행동을 재는 eval을 만들어라".

> **교훈.** 지표를 만들면 **상수 전략(항상 같은 답)**으로 그 지표를 찍어 봐야 한다. 상수 전략이 이기면 지표가 틀린 것이다.

#7 정답은 설계자 한 명의 판단이었다

증상. 사례·정답·규칙·점검을 모두 같은 설계자(LLM)가 했다. 실제로 점검 중 개입 사례 3개(S002, S022, S044)가 "독립 신호 2개 이상" 규칙을 스스로 어기고 있었다. 또 Claude가 만든 벤치마크를 Claude로 평가하면 "출제자와 같은 생각"이 점수로 나올 위험이 있었다.

비교 (판정 전)	일치율	kappa
라벨러 A vs 설계자 / 라벨러 B vs 설계자	0.84 / 0.81	0.75 / 0.71
라벨러 A vs B / 세 명 Fleiss	0.80 / —	**0.68** / 0.71

라벨러 피드백에서 "직장인인데 일정이 수업"(5건)을 고쳤고, "중복"으로 보인 6쌍은 의도된 반례 쌍이라 안내문에 설명을 넣었다. 두 라벨러가 함께 설계자와 다른 5개는 다수결로 고쳤다. 라벨러가 엑셀로 다시 저장한 파일(행 전체가 따옴표로 묶임)을 읽도록 `agreement.py` 도 고쳤다.

> **강의 연결.** Ch03 p.26 Human evaluation의 단점 "Inter-annotator disagreement". 판단 보류 범주의 일치도(0.56, 0.33)가 가장 낮았다 — 사람도 갈리는 범주는 정답 자체가 불확실하다.

> **교훈.** 설계자의 자체 점검은 **일관성**만 보여 주고 **타당성**은 보여 주지 못한다. 판정 후 일치도는 낙관적이므로 신뢰도는 판정 전 값으로 보고한다.

#13 원문을 버리고 있었다 — 그래서 파서를 고칠 때마다 다시 돌려야 했다

```
# run_agent.py — 원문을 저장하고, 모델 없이 현재 파서로 재해석
act, why = parse(call_llm(SYSTEM_PROMPT_EN if a.lang == "en" else SYSTEM_PROMPT, build_user_message(r, a.lang), a))
raw = call_llm(SYSTEM_PROMPT_EN if a.lang == "en" else SYSTEM_PROMPT, build_user_message(r, a.lang), a)
act, why = parse(raw)
f.write(json.dumps({"case_id": r["case_id"], "run": run, "action": act, "reason": why, "raw": raw}) + "\n")
ap.add_argument("--reparse", ...)   # 저장된 원문(.jsonl)을 현재 파서로 다시 해석
ap.add_argument("--cases", ...)     # 시험 실행: S001,S039 ... 만
```

> **교훈.** 가장 비싼 것(모델 호출)의 결과는 **가공하기 전 원형 그대로** 남긴다. 본 실행 전에는 대표 사례 12개로 **시험 실행**을 하고 판단 근거를 사람이 읽는다. 무엇을 바꾸면 재실행이 필요한지(입력·프롬프트·도구)와 필요 없는지(파서·지표)를 미리 구분해 두고, 시험 실행 후에는 **동결**한다.

3. 실행기(하네스)의 시행착오

#8 출력 길이 제한 150토큰

```
model=a.model, max_tokens=150, temperature=a.temperature,
model=a.model, max_tokens=300, temperature=a.temperature,
ap.add_argument("--timeout", type=float, default=90, ...)
ap.add_argument("--timeout", type=float, default=120, ...)
```

EXAONE은 실제로 응답을 ```` ```json ... ``` ```` 코드 블록으로 감싸고 근거를 2~3문장 썼다. 150토큰이면 긴 근거에서 JSON 끝이 잘려 형식 오류가 된다. 실행 전 예방 조치라 효과를 수치로 재지는 않았다.

> **강의 연결.** Ch04 p.46 출력 토큰이 비용과 지연을 정한다 — 그래서 줄이고 싶지만, 너무 줄이면 출력 형식이 깨진다.

#9 파서가 너무 순진했다

```
# 수정 전: 첫 '{'부터 마지막 '}'까지를 한 덩어리로 (탐욕적 정규식)
m = re.search(r"\{.*\}", text, re.S)
d = json.loads(m.group(0))
# 수정 후: 괄호 짝으로 덩어리를 하나씩 꺼내 첫 번째 유효한 것, 코드 블록·끝 쉼표 허용
t = (text or "").replace("```json", "").replace("```", "")
for cand in _objects(t):                    # 문자열 안의 { } 는 건너뛰는 괄호 짝 탐색
    for c in (cand, re.sub(r",\s*([}\]])", r"\1", cand)):
        ... if isinstance(d, dict) and "action" in d: return d
```

모델 출력	수정 전	수정 후
`Let me check. {"tool": ...} then {"action": "x"}`	PARSE_ERROR (두 JSON을 한 덩어리로)	첫 번째 도구 호출
`{"action": "gentle_prompt", "reason": "late night",}`	PARSE_ERROR	정상
`I think the user is on autopilot.`	PARSE_ERROR	PARSE_ERROR (그래야 맞다)

> **강의 연결.** Ch04 p.37 Structured Output — "프롬프트로만 JSON을 요구하면 키가 빠지고 설명이 섞이고 JSON이 깨진다 → parse-and-retry 코드". 로컬 모델에는 Structured Outputs(제약 디코딩)가 없어서 이 단계를 우리가 직접 견고하게 만들어야 했다.

#10 통계를 내려면 숫자 39개를 다시 적어야 했다

증상. 트랙 B 본 실행에서 `get_touch_log` 바로 다음에 `PARSE_ERROR`가 연달아 났다 (S068, S070, S071, S072 ...).

원인. 터치 기록은 간격·속도·방향 각 39개였다. 통계를 보려면 에이전트가 그 숫자를 JSON 안에 직접 다시 적어 `compute_stats`에 넘겨야 했다. 7B 모델은 `[33.1, 43.3, ...]`처럼 중간을 생략했고, 형식 오류 기회는 1번뿐이었다.

```
# run_agent_tools.py
x = np.array([float(t) for t in (args or {}).get("values", [])])
field = str(args.get("field", "")).strip()
if field or not isinstance(vals, list) or len(vals) < 2:   # 필드 이름이면 터치 기록에서 바로 계산
    vals = log.get(field if field in ("swipe_intervals_sec", "swipe_speed_px_per_s") else "swipe_intervals_sec", [])
- compute_stats: args {"values": [numbers]} -> n, mean, ...
- compute_stats: args {"field": "swipe_intervals_sec"} or {"field": "swipe_speed_px_per_s"} -> ...
if format_errors > 1:
if format_errors > 2:          # 안내 2번, 안내문에 field 방식 예시
```

결과. 재실행에서 `compute_stats`는 102번 모두 `field` 방식으로 호출됐고, 형식 오류는 4건(5%)으로 줄었다. 남은 4건은 `{"get_user_context": {}}`처럼 도구 이름을 키로 쓴 경우다.

> **강의 연결.** Ch04 p.44 **"Don't make the LLM compute what your program can"** — 계산·집계·조회는 코드가 하고 LLM은 이해와 판단만. Ch11 p.12 "Offload the burden from the model … Don't make the model fill arguments you already know", "Pass the intern test". Ch03 p.59·66 같은 모델도 하네스에 따라 점수가 3~20점 이상 달라진다.

> **교훈.** 도구 인자는 **모델이 이미 받은 데이터를 다시 옮겨 적게** 설계하면 안 된다. 모델은 "무엇을"(어느 필드)만 고르고, 데이터는 실행기가 들고 있어야 한다. 이 버그는 모델의 판단력이 아니라 **하네스의 결함**이 점수를 깎은 경우다.

#11 "Usage concentration"을 주의력 점수로 읽었다

증상. EXAONE 트랙 A의 판단 근거 중 **72%**가 "concentration"을 언급했다. 예: *"The high concentration level and positive self-reported mood indicate intentional study behavior."* 이 값이 높으면 개입하지 않는 경향도 보였다(개입 안 함 예측 중앙값 0.76, 개입 예측 0.50).

원인. `usage_quadratic`은 "1시간 사용이 긴 세션 하나에 몰린 정도"다. 세션이 1개면 항상 1.0이고 세션 수와 상관 −0.67. 하지만 프롬프트의 이름표는 "Usage concentration (0-1)"뿐이었다.

```
# run_agent.py FIELDS_EN (트랙 B OBS도 동일)
("usage_quadratic", "Usage concentration (0-1)")
("usage_quadratic", "Session concentration (0-1): share of the hour's use packed into one long session,
                    1 = a single session; not a measure of attention")
```

같은 12개 사례, EXAONE 트랙 A	수정 전	수정 후
정확도	0.58	0.58
같은 답을 고른 사례	12개 중 11개	
근거에 "concentration" 언급	78%	33%
"high concentration level"(주의력 해석)	**44%**	**0%**

수정 후 근거는 *"The high **session** concentration … indicate intentional engagement"*처럼 **사용 패턴**으로 읽었고, S066에서는 같은 값을 자동조종 쪽 근거로 썼다. **판단 결과는 거의 같았지만 판단 근거가 바뀌었다.** 정확도만 봤다면 찾지 못했을 결함이다.

> **강의 연결.** Ch11 p.12 "Write clear and detailed … parameter descriptions … what the output represents", Ch13 p.24 "Write descriptions well understood by LLMs". Ch04 p.39 Rule 7 — 하지 말 것만이 아니라 무엇인지를 말하라 ("not a measure of attention" + 무엇을 재는지).

#12 CV의 방향만 알려 주고 눈금은 알려 주지 않았다

증상. "uniform swipe"라고 말한 근거 20건 중 **10건이 CV 0.75~2.0인 불규칙한 사례**였다. S030(CV 2.0)을 *"consistent reading pattern … uniform swipe intervals"*로 읽었다.

```
("swipe_interval_cv", "Swipe interval coefficient of variation (lower = more uniform)")
("swipe_interval_cv", "Swipe interval variability, CV (0 = perfectly regular; about 0.3 or lower = very regular;
                      about 1 or higher = irregular)")
("usage_sessions", "Number of sessions")
("usage_sessions", "Number of sessions in the last 60 minutes")
("avg_dwell_sec", "Average dwell per item (sec)")
("avg_dwell_sec", "Average time on each item (post or video) before swiping (sec)")
```

지름길 위험은 없나. "CV가 낮으면 자동조종"이라는 **판단**을 적으면 #1의 지름길(B3)을 가르치게 된다. 여기서는 **숫자를 읽는 법**(0.3과 1이 각각 무엇인지)만 적었다.

> **강의 연결.** Ch04 p.39 Rule 6 **"give numbers, not adjectives"** — "lower = more uniform"은 형용사형 설명이었고, 기준점 숫자가 필요했다. Ch04 p.45 "시각 대신 경과 시간을 알려 줘라"도 같은 원리다 — 우리가 일정에 "bedtime goal 24:00 (70 min past)"처럼 경과 시간을 미리 계산해 넣은 이유.

> **교훈 (#11, #12 공통).** 열 이름과 설명은 **사람에게 자명해도 모델에게는 아니다**. 판단 근거(`reason`)를 열별로 검색해 "이 열을 어떻게 읽었나"를 확인하는 것이 가장 빠른 점검 방법이었다. 설명은 ① 무엇을 재는지 ② 단위·기간 ③ 눈금의 기준점 ④ 흔한 오해(무엇이 아닌지)를 담는다.

4. 고치지 않은 것

#14 트랙 B: 균일한 스와이프를 "집중"으로 읽고, 맥락은 40%만 확인했다

설명 수정 전, 하네스 수정 후의 결과다.

EXAONE 7.8B	정확도	탐지율	불필요 개입	맥락 확인율
트랙 A (정보를 한 번에 받음)	0.63	0.79	0.25	— (항상 있음)
트랙 B (도구로 스스로 모음)	**0.36**	**0.12**	0.06	0.40

```
# predictions_exaone_B.jsonl, S039 (밤 11:50, 알림으로 진입해 쇼츠 412개 연속 재생) — 실제 대화
a: {"tool": "get_touch_log", "args": {}}
u: Tool result: {"swipe_intervals_sec": [6.8, 6.4, 5.9, 6.1, ...], ...}
a: {"tool": "compute_stats", "args": {"field": "swipe_intervals_sec"}}
u: Tool result: {"n": 40, "mean": 6.01, "median": 5.95, "std": 0.74, "cv": 0.123, ...}
a: {"tool": "get_user_context", "args": {}}
u: Tool result: {... "recent_context": "Entry: tapped a recommended-video notification | In app: played 412 short videos ..."}
a: {"action": "no_intervention", "reason": "The user's swipe patterns show consistent engagement typical of intentional viewing
..."}
```

피치 덱의 "균일한 스와이프 = 좀비 스크롤"과 정반대로 읽었다. 맥락까지 확인한 뒤에도 처음 본 터치 통계의 인상을 따랐다. **이것은 고치지 않는다.** #11·#12는 벤치마크가 **잘못되거나 모호한 설명**을 준 결함이지만, 여기서는 설명이 정확한데 **모델이 다르게 해석**했다. "받은 데이터를 맥락과 함께 올바르게 해석하는가"가 바로 트랙 B가 재려는 능력이다.

> **강의 연결.** Ch13 p.4~5·16~18 **AI Workflow vs AI Agent** — 트랙 A는 정해진 정보 흐름(워크플로)에, 트랙 B는 스스로 도구를 고르는 에이전트에 가깝다. 강의의 권고 "First, try AI Workflows"가 작은 모델에서는 그대로 맞았다. Ch13 p.22 "필요한 정보를 받지 못하면 실패한다" — 트랙 B는 정보를 **받을 수 있었는데 고르지 않았다**. Ch03 p.46 에이전트 벤치마크는 답 하나가 아니라 궤적을 채점한다 — 그래서 `context_check_rate`를 따로 잰다.
> **Ch05 p.2~4 근거 없는 생성(deviation)** — 외부 정보가 없으면 LLM은 자기 사전 지식으로 답한다. 맥락을 확인하지 않은 사례의 EXAONE은 "일정한 스와이프 = 집중"이라는 통념으로 판단했다. **Ch05 p.50 Agentic RAG** — "LLM이 필요한 정보를 스스로 찾게 한다"가 바로 `get_user_context`이고, 작은 모델은 그것을 40%만 찾았다. Ch13 p.25~26은 이 때문에 **항상 넣어 주는 정보(RAG) + 필요할 때 찾는 정보(agentic retrieval)의 하이브리드**를 권한다. Phase 3에서 이 벤치마크로 에이전트를 만든다면 선언 목표와 관찰 기록은 처음부터 넣어 주고, 터치 기록만 도구로 찾게 하는 설계가 첫 번째 개선 후보다.

#15 남은 설계 부채: 출력 키 순서가 "행동 → 근거"다

```
# 현재 프롬프트가 요구하는 출력
{"action": "<one of the three actions>", "reason": "<1-2 sentences>"}
# 강의(Ch04 p.42~43)가 권하는 순서
{"reason": "...", "action": "..."}
```

자기회귀 생성에서는 앞에 생성된 토큰만 뒤의 토큰에 영향을 준다. 지금 형식은 **행동을 먼저 고르고, 근거는 그 행동을 정당화하는 문장으로** 나온다. 근거를 먼저 쓰게 하면 근거가 실제로 판단에 쓰인다. 다만 이번 실험은 이미 동결했고 바꾸면 모든 결과를 다시 내야 해서 **보류**했다. Phase 3에서 이 벤치마크로 에이전트를 만드는 팀은 이 순서부터 바꾸는 것이 가장 싼 개선일 수 있다. 이 문서에서 판단 근거(`reason`)를 "모델이 어떻게 생각했는가"의 증거로 쓸 때 이 한계를 감안해야 한다.

5. 통찰: 에이전트를 만들 때 확인할 것

5.1 코드 수준

확인할 것	구체적인 방법	근거
도구 인자에 모델이 옮겨 적을 데이터가 있는가	모델은 이름·ID·필드만 고르고, 실제 데이터는 실행기가 들고 있게 한다 (`{"field": "swipe_intervals_sec"}`)	#10 · Ch04 p.44, Ch11 p.12
출력 파서가 흔한 형식 실수를 견디는가	코드 블록, 앞뒤 설명, JSON 여러 개, 끝 쉼표를 테스트 케이스로 만든다. 설명만 있는 응답은 여전히 오류여야 한다. 가능하면 Structured Outputs를 쓴다	#9 · Ch04 p.37
형식 오류 시 기회와 안내가 충분한가	재시도 횟수, 안내 문구에 올바른 예시 포함. 형식 오류율을 지표로 따로 잰다	#10
출력 토큰 한도가 형식을 자르지 않는가	모델의 실제 출력 길이(코드 블록 포함)를 보고 여유를 둔다	#8 · Ch04 p.46
모델 원문을 저장하는가	가공 전 원문을 `.jsonl`로. 파서·지표를 고쳐도 재실행 없이 재채점	#13
입력 열마다 설명이 충분한가	무엇을 재는지, 단위·기간, 눈금 기준점, 흔한 오해. "인턴 테스트": 이 설명만으로 사람이 정확히 읽을 수 있나	#11·#12 · Ch11 p.12
출력 스키마의 키 순서	근거 → 결정 순서로. 결정이 근거에 실제로 의존하게 한다	#15 · Ch04 p.42
계산은 코드가 했는가	경과 시간, 횟수, 통계는 미리 계산해 준다 ("bedtime goal 24:00 (70 min past)")	Ch04 p.45

5.2 개념 수준

확인할 것	구체적인 방법	근거
이 데이터를 맥락 없이 풀 수 있는가	모든 열·단어에 대해 단일 규칙 정확도를 재고, 진단용 분류기(B4)로 문장 단서를 잰다. 지름길은 기준선으로 만든다	#1·#2·#4 · Ch03 p.60
지표를 찍기로 이길 수 있는가	상수 전략(항상 같은 답)으로 모든 지표를 계산해 본다. 가중치는 민감도 분석으로 보고	#3 · Ch03 p.40
정답이 설계자만의 판단인가	독립 라벨러, 판정 전 kappa로 신뢰도 보고, 범주별 일치도 확인	#7 · Ch03 p.26
입력이 판단을 대신해 주지 않는가	요약("검색 없음")이 아니라 관찰("검색 0", 모든 사례에 같은 칸)	#4 · Ch13 p.22
결함과 측정 결과를 구분하는가	벤치마크가 잘못된 정보를 줬으면 고친다(#11·#12). 정보는 옳은데 모델이 틀렸으면 기록한다(#14)	#14
점수뿐 아니라 근거를 읽는가	설명 수정 후 정확도는 같았지만 근거가 바뀌었다. 판단 근거를 열별로 검색한다	#11 · Ch04 p.66
워크플로로 충분한가, 에이전트가 필요한가	같은 모델로 둘 다 재 본다. 작은 모델은 정보를 스스로 고르게 하면 크게 떨어졌다(0.63 → 0.36)	#14 · Ch13 p.17~18
꼭 필요한 정보를 넣어 주는가, 찾게 하는가	판단에 항상 필요한 정보(선언 목표, 관찰 기록)는 처음부터 넣고, 비싸거나 가끔 필요한 정보(터치 기록)만 도구로 찾게 한다. 찾게 했다면 실제로 찾았는지 (`context_check_rate`)를 잰다	#14 · Ch05 p.50, Ch13 p.25~26
실제 모델로 일찍 돌려 봤는가	mock과 가짜 응답은 형식만 확인한다. 대표 사례로 시험 실행 → 근거 확인 → 동결 → 본 실행	#10~#13

6. 강의 내용과의 대응

강의 (슬라이드)	내용	이 프로젝트에서 겪은 일
Ch03 p.26 Human evaluation	평가자 간 불일치, 재현성	#7 라벨러 2명, kappa 0.68~0.75, 판단 보류 범주가 가장 불일치
Ch03 p.29~30, p.60 Contamination · Reward hacking	과제 대신 허점을 푸는 모델	#1·#2·#4 CV·체류·부정어 지름길, B3·B4로 측정
Ch03 p.40 Goodhart의 법칙	측정치가 목표가 되면 망가진다	#3 항상 묻기가 비용 점수 1위, 여러 지표를 함께 성공 기준으로
Ch03 p.46~47 Agentic benchmark	궤적 채점, 반복 시행, pass^k	트랙 B 도구 사용 지표, 3회 실행 일관성
Ch03 p.59, p.66 하네스 의존성	같은 모델도 하네스에 따라 점수가 크게 바뀜	#10 숫자 복사 도구 → 연속 형식 오류, #14 같은 모델 A 0.63 / B 0.36
Ch04 p.37 Structured Output	프롬프트로만 JSON 요구 → 깨짐 → 파싱·재시도	#8·#9 출력 한도, 견고한 파서
Ch04 p.39 Rule 6·7	형용사 대신 숫자, 하지 말 것 대신 할 것	#11 "not a measure of attention" + 정의, #12 CV 기준점 0 / 0.3 / 1
Ch04 p.42~43 Reason first	스키마 키 순서 = 생성 순서	#15 현재 action → reason, 향후 과제
Ch04 p.44~45 계산은 코드로	조회·계산·경과 시간은 프로그램이	#10 `field` 인자, 일정의 "(70 min past)"
Ch04 p.66 Build evals	프롬프트 행동을 재는 평가를 만들어라	#13 시험 실행, 판단 근거 열별 검색
Ch05 p.2~4 RAG의 필요성	외부 근거가 없으면 사전 지식으로 답하다 빗나감(deviation)	#14 맥락을 확인하지 않은 판단은 "일정 = 집중"이라는 통념을 따름
Ch05 p.32~35 Keyword vs Vector search	단어 일치와 의미 유사도의 차이	#4 B4(단어 빈도 분류기)로 문장 표면 단서를 측정, 의미 단어만 남김
Ch05 p.50 Agentic RAG (+ Ch13 p.25~26 하이브리드)	LLM이 스스로 정보를 찾게 함, RAG와 섞는 전략	#14 트랙 B 맥락 확인율 40%, Phase 3 개선 방향으로 하이브리드 제안
Ch11 p.7 도구 프롬프트 형식	모델이 학습한 도구 형식을 따르는 편이 정확	모든 모델에 같은 조건을 주려고 JSON 한 줄 프로토콜 사용 → 형식 오류를 직접 다뤄야 했음(#9·#10)
Ch11 p.12 함수 정의 모범 사례	명확한 설명, 최소 놀람, 인턴 테스트, 모델 부담 줄이기	#10 도구 인자, #11·#12 열 설명
Ch12 Memory	사용자 메타데이터, 의미 기억	#6 사용자 상태, 평소 사용량(실제 값)을 사용자 기억처럼 제공
Ch13 p.4~5, 16~18 Workflow vs Agent	먼저 워크플로를 시도하라	#14 작은 모델에서 트랙 A(워크플로형) > 트랙 B(에이전트형)
Ch13 p.19~24 Context engineering	필요한 정보를 적절히, 도구 설명은 명확히	#4 관찰 기록, #14 맥락 확인율 40%, #11·#12 설명

정직하게 남겨 둘 한계

- 설계와 실행기를 만든 쪽(Claude)은 실제 모델을 직접 돌릴 수 없는 환경에서 작업했다. 형식 오류(#10)와 해석 문제(#11·#12)가 사용자의 실제 실행에서야 드러난 가장 큰 이유다. 결과적으로 "실제 모델로 일찍 시험 실행"이 가장 비용 대비 효과가 큰 점검이었다.
- #11의 효과는 12개 사례 시험 실행으로만 확인했다. 81개 전체의 수정 후 결과는 현재 실행 중이다.
- #14의 트랙 B 결과는 설명 수정(#11·#12) 전 실행이다. 수정 후 결과가 달라질 수 있다.
- 판단 근거(`reason`)는 #15 때문에 사후 정당화일 수 있다. 근거 분석은 "모델이 어떤 정보를 언급했는가"의 증거로만 쓴다.